파이썬 머신러닝 판다스 데이터분석

Lecture (9)

Dr. Heesuk Kim

목차

Part 1. 판다스 입문

4-1. 시리즈 연산

- **연산 메소드 활용**

  - 객체 사이에 공통 인덱스가 없는 경우에 NaN으로 반환.
  - 이런 상황을 피하려면 연산 메소드에 fill_value 옵션을 설정.

  ※ 다음 예제는 누락 데이터 NaN 대신 숫자 0을 입력하는 것을 예시로 설명.

연산 메소드 사용(시리즈와 시리즈 덧셈): `Series1.add(Series2, fill_value=0)`

예제 1-24 연산 메소드 사용 – 시리즈 연산 (File: example/part1/1.24_series_to_series3.py)

```
1  # -*- coding: utf-8 -*-
2
3  # 라이브러리 불러오기
4  import pandas as pd
5  import numpy as np
6
7  # 딕셔너리 데이터로 판다스 시리즈 만들기
8  student1 = pd.Series({'국어':np.nan, '영어':80, '수학':90})
9  student2 = pd.Series({'수학':80, '국어':90})
10
11 print(student1)
12 print('\n')
13 print(student2)
14 print('\n')
15
16 # 두 학생의 과목별 점수로 사칙연산 수행(연산 메소드 사용)
17 sr_add = student1.add(student2, fill_value=0)     # 덧셈
18 sr_sub = student1.sub(student2, fill_value=0)     # 뺄셈
19 sr_mul = student1.mul(student2, fill_value=0)     # 곱셈
20 sr_div = student1.div(student2, fill_value=0)     # 나눗셈
21
22 # 사칙연산 결과를 데이터프레임으로 합치기(시리즈 -> 데이터프레임)
23 result = pd.DataFrame([sr_add, sr_sub, sr_mul, sr_div],
24                        index=['덧셈', '뺄셈', '곱셈', '나눗셈'])
25 print(result)
```

〈실행 결과〉 코드 전부 실행

```
국어     NaN
영어    80.0
수학    90.0
dtype: float64


수학    80
국어    90
dtype: int64


        국어      수학        영어
덧셈    90.0   170.000  80.000000
뺄셈   -90.0    10.000  80.000000
곱셈     0.0  7200.000   0.000000
나눗셈   0.0     1.125        inf
```

연산 메소드에 fill_value=0 옵션을 설정하여 student1의 국어 점수와 student2의 영어 점수는 NaN 대신 0으로 입력된다. 한편 result의 '영어' 열의 나눗셈 값은 무한대(inf)이다. student1의 영어 점수 80을 student2의 영어 점수 0으로 나눈 값이기 때문이다.

Part 1. 판다스 입문 [화면 녹화]

예제 1-24

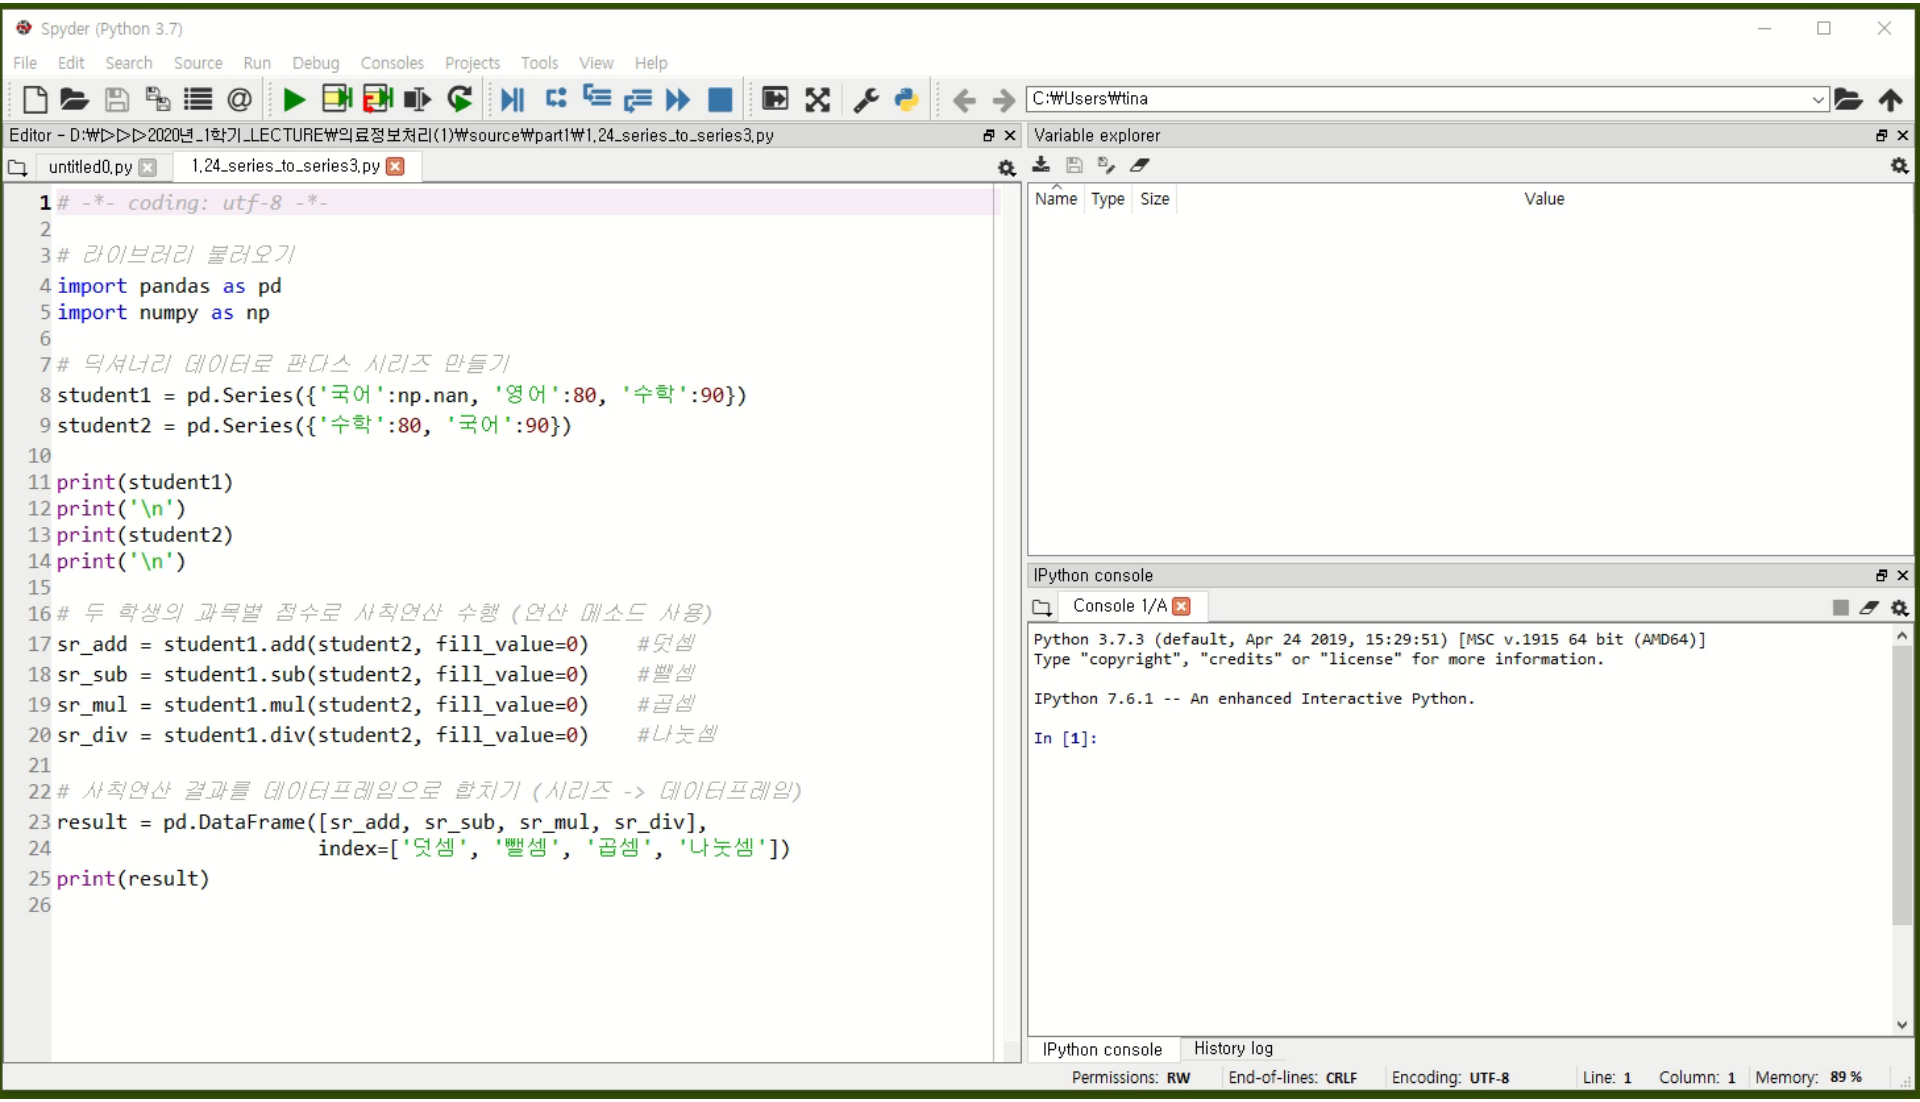

4-2. 데이터프레임 연산

데이터프레임은 여러 시리즈가 한데 모인 것이므로, 시리즈 연산을 확장하는 개념으로 이해한다. 먼저 행/열 인덱스를 기준으로 정렬하고, 일대일 대응되는 원소끼리 연산한다.

- **데이터프레임 vs. 숫자**

  - 데이터프레임에 어떤 숫자를 더하면, 모든 원소에 숫자를 더한다. 덧셈, 뺄셈, 곱셈, 나눗셈 모두 가능하다.
  - 기존 데이터프레임의 형태를 그대로 유지한 채, 원소 값만 새로운 값으로 바뀐다.

데이터프레임과 숫자 연산: DataFrame 객체 + 연산자(+, -, *, /) + 숫자

예제 1-25 데이터프레임에 숫자 더하기 (File: example/part1/1.25_df_to_number.py)

```
# -*- coding: utf-8 -*-

# 라이브러리 불러오기
import pandas as pd
import seaborn as sns

# titanic 데이터셋에서 age, fare 2개 열을 선택하여 데이터프레임 만들기
titanic = sns.load_dataset('titanic')
df = titanic.loc[:, ['age','fare']]
print(df.head())          # 첫 5행만 표시
print('\n')
print(type(df))
print('\n')

# 데이터프레임에 숫자 10 더하기
addition = df + 10
print(addition.head())    # 첫 5행만 표시
print('\n')
print(type(addition))
```

〈실행 결과〉 코드 전부 실행

```
    age     fare
0  22.0   7.2500
1  38.0  71.2833
2  26.0   7.9250
3  35.0  53.1000
4  35.0   8.0500


<class 'pandas.core.frame.DataFrame'>


    age     fare
0  32.0  17.2500
1  48.0  81.2833
2  36.0  17.9250
3  45.0  63.1000
4  45.0  18.0500

class 'pandas.core.frame.DataFrame'>
```

※ 타이타닉('titanic') 데이터셋

Seaborn 라이브러리에서 제공하는 데이터셋으로, 타이타닉호 탑승자에 대한 인적사항과 구조 여부 등을 정리한 자료이다.

load_dataset() 함수로 불러온다.

[Seaborn 내장 데이터셋의 종류]

'anscombe', 'attention', 'brain_networks', 'car_crashes', 'diamonds', 'dots', 'exercise', 'flights', 'fmri', 'gammas', 'iris', 'mpg', 'planets', 'tips', 'titanic'

seaborn 설치

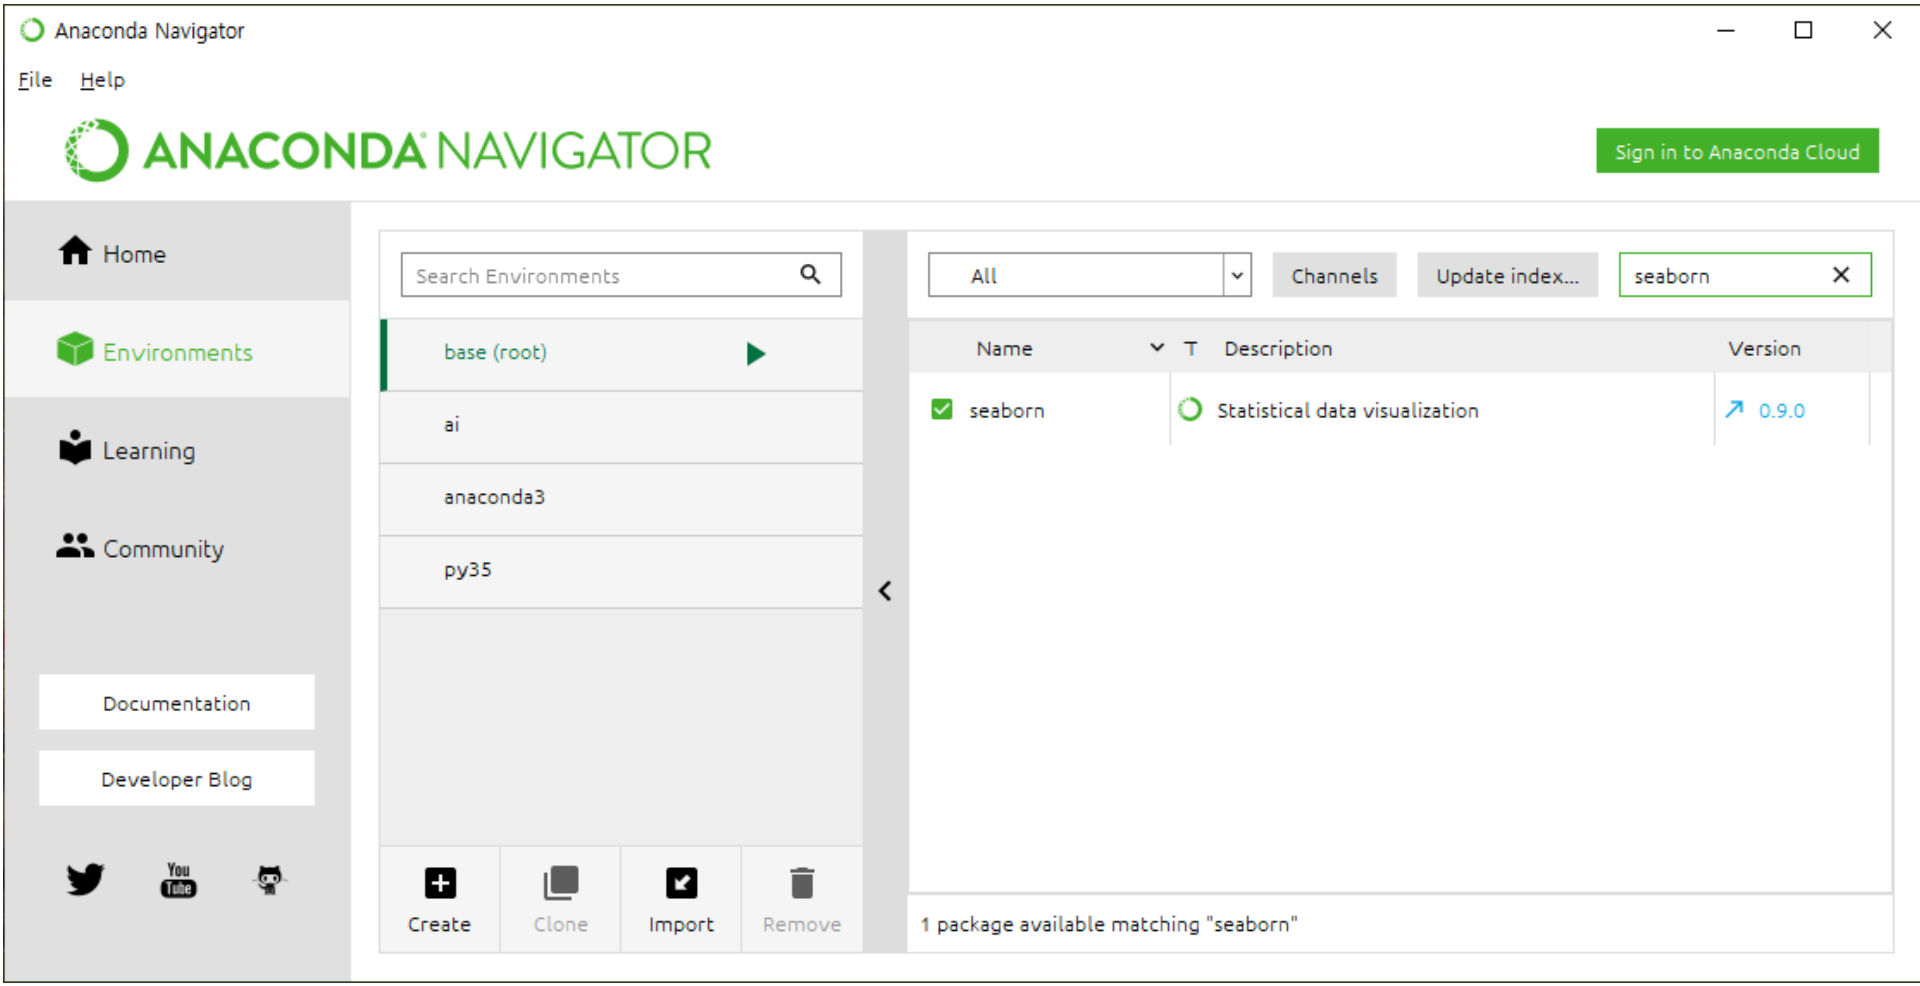
Anaconda Navigator
File Help
ANACONDA NAVIGATOR
Sign in to Anaconda Cloud
Home
Environments
Learning
Community
Documentation
Developer Blog
Search Environments
base (root)
ai
anaconda3
py35
Create
Clone
Import
Remove
All
Channels
Update index...
seaborn
Name
T
Description
Version
seaborn
Statistical data visualization
0.9.0
1 package available matching "seaborn"

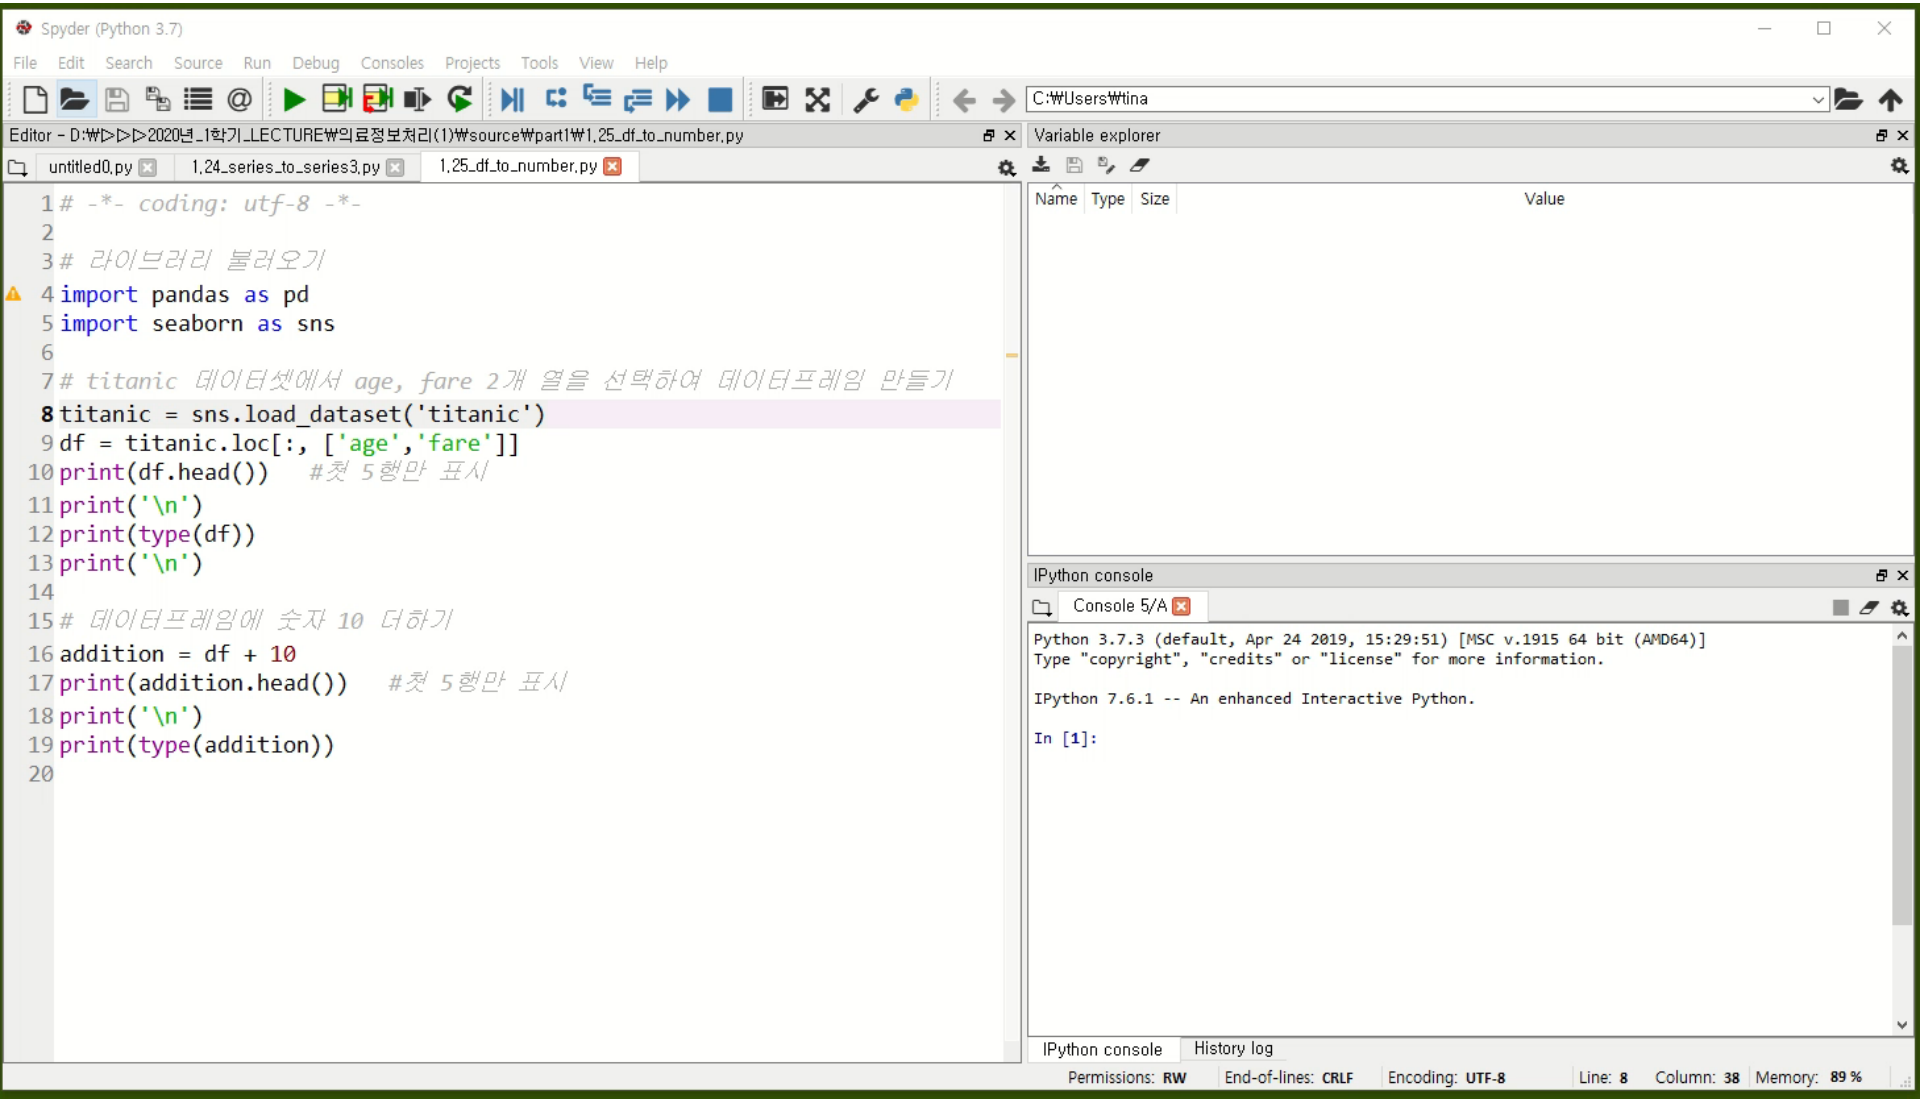
Spyder (Python 3.7)
File Edit Search Source Run Debug Consoles Projects Tools View Help
C:₩Users₩tina
Editor - D:₩▷▷▷2020년_1학기_LECTURE₩의료정보처리(1)₩source₩part1₩1_25_df_to_number.py
untitled0.py
1_24_series_to_series3.py
1_25_df_to_number.py
1 # -*- coding: utf-8 -*-
2
3 # 라이브러리 불러오기
4 import pandas as pd
5 import seaborn as sns
6
7 # titanic 데이터셋에서 age, fare 2개 열을 선택하여 데이터프레임 만들기
8 titanic = sns.load_dataset('titanic')
9 df = titanic.loc[:, ['age','fare']]
10 print(df.head()) #첫 5행만 표시
11 print('\n')
12 print(type(df))
13 print('\n')
14
15 # 데이터프레임에 숫자 10 더하기
16 addition = df + 10
17 print(addition.head()) #첫 5행만 표시
18 print('\n')
19 print(type(addition))
20
Variable explorer
Name Type Size Value
IPython console
Console 5/A
Python 3.7.3 (default, Apr 24 2019, 15:29:51) [MSC v.1915 64 bit (AMD64)]
Type "copyright", "credits" or "license" for more information.
IPython 7.6.1 -- An enhanced Interactive Python.
In [1]:
IPython console
History log
Permissions: RW
End-of-lines: CRLF
Encoding: UTF-8
Line: 8
Column: 38
Memory: 89 %

4-2. 데이터프레임 연산

- **데이터프레임 vs. 데이터프레임**

  - 각 데이터프레임의 같은 행, 같은 열 위치에 있는 원소끼리 계산한다. 이처럼 동일한 위치의 원소끼리 계산한 결과값을 원래 위치에 다시 입력하여 데이터프레임을 만든다.

데이터프레임의 연산자 활용: DataFrame1 + 연산자(+, -, *, /) + DataFrame2

df1

	열 A	열 B	열 C
행 0	15	100	1
행 1	20	500	2
행 2	50	200	3
행 3	NaN	500	2
행 4	NaN	200	3

+

df2

	열 A	열 B
행 0	10	200
행 1	10	100
행 2	10	200
행 3	20	100
행 4	30	100

=

df1+df2

	열 A	열 B	열 C
행 0	25	300	NaN
행 1	30	600	NaN
행 2	60	400	NaN
행 3	NaN	600	NaN
행 4	NaN	300	NaN

[그림 1-19] 데이터프레임의 산술연산(덧셈)

예제 1-26 데이터프레임끼리 더하기 (File: example/part1/1.26_df_to_df.py)

```
1  # -*- coding: utf-8 -*-
2
3  # 라이브러리 불러오기
4  import pandas as pd
5  import seaborn as sns
6
7  # titanic 데이터셋에서 age, fare 2개 열을 선택하여 데이터프레임 만들기
8  titanic = sns.load_dataset('titanic')
9  df = titanic.loc[:, ['age','fare']]
10 print(df.tail())          # 마지막 5행 표시
11 print('\n')
12 print(type(df))
```

```
15 # 데이터프레임에 숫자 10 더하기
16 addition = df + 10
17 print(addition.tail())          # 마지막 5행 표시
18 print('\n')
19 print(type(addition))
20 print('\n')
21
22 # 데이터프레임끼리 연산하기(additon - df)
23 subtraction = addition - df
24 print(subtraction.tail())       # 마지막 5행 표시
25 print('\n')
26 print(type(subtraction))
```

〈실행 결과〉 코드 전부 실행

```
      age   fare
886  27.0  13.00
887  19.0  30.00
888   NaN  23.45
889  26.0  30.00
890  32.0   7.75

<class 'pandas.core.frame.DataFrame'>

      age   fare
886  37.0  23.00
887  29.0  40.00
888   NaN  33.45
889  36.0  40.00
890  42.0  17.75

<class 'pandas.core.frame.DataFrame'>

      age  fare
886  10.0  10.0
887  10.0  10.0
888   NaN  10.0
889  10.0  10.0
890  10.0  10.0

<class 'pandas.core.frame.DataFrame'>
```

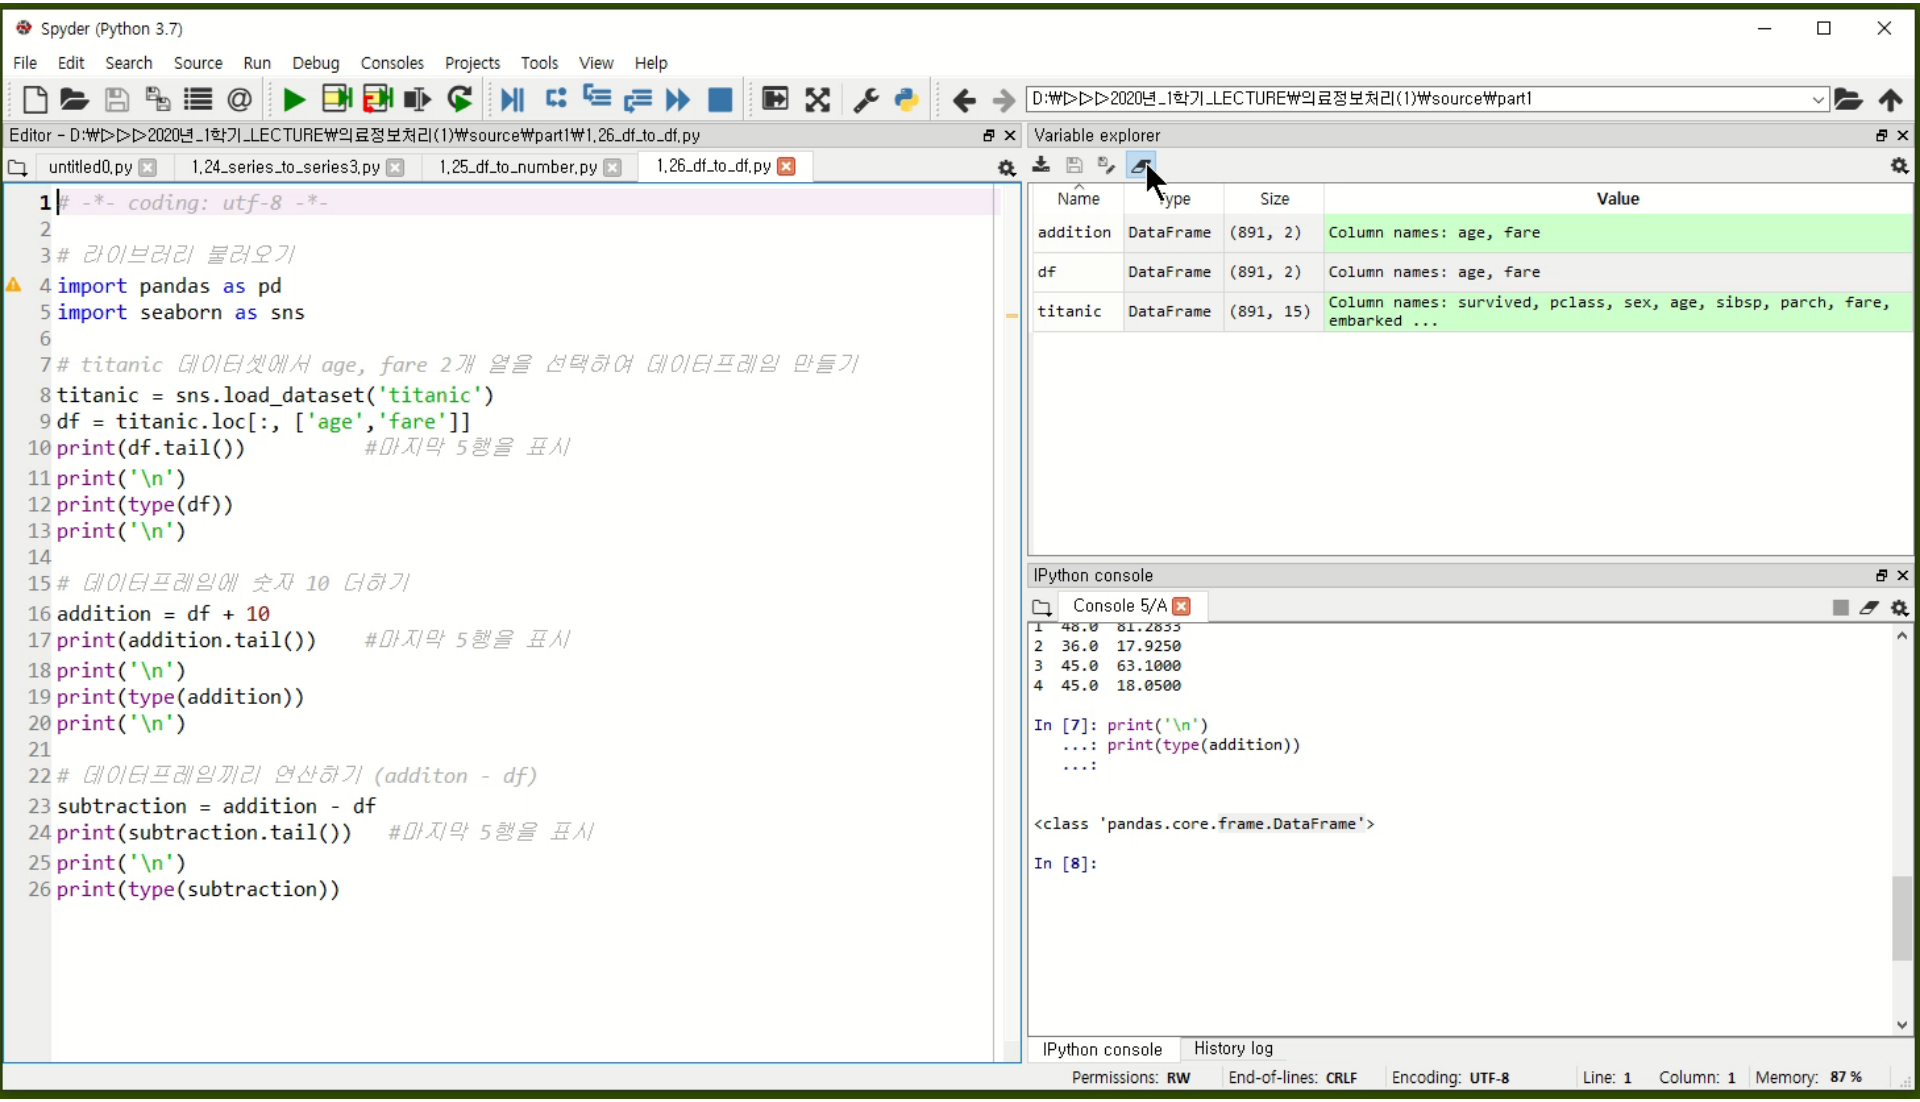
Spyder (Python 3.7)
File Edit Search Source Run Debug Consoles Projects Tools View Help
Editor - D:₩▷▷▷2020년_1학기_LECTURE₩의료정보처리(1)₩source₩part1₩1_26_df_to_df.py
untitled0.py
1_24_series_to_series3.py
1_25_df_to_number.py
1_26_df_to_df.py
# -*- coding: utf-8 -*-
# 라이브러리 불러오기
import pandas as pd
import seaborn as sns
# titanic 데이터셋에서 age, fare 2개 열을 선택하여 데이터프레임 만들기
titanic = sns.load_dataset('titanic')
df = titanic.loc[:, ['age','fare']]
print(df.tail()) #마지막 5행을 표시
print('\n')
print(type(df))
print('\n')
# 데이터프레임에 숫자 10 더하기
addition = df + 10
print(addition.tail()) #마지막 5행을 표시
print('\n')
print(type(addition))
print('\n')
# 데이터프레임끼리 연산하기 (additon - df)
subtraction = addition - df
print(subtraction.tail()) #마지막 5행을 표시
print('\n')
print(type(subtraction))
Variable explorer
Name Type Size Value
addition DataFrame (891, 2) Column names: age, fare
df DataFrame (891, 2) Column names: age, fare
titanic DataFrame (891, 15) Column names: survived, pclass, sex, age, sibsp, parch, fare, embarked ...
IPython console
Console 5/A
2 36.0 17.9250
3 45.0 63.1000
4 45.0 18.0500
In [7]: print('\n')
...: print(type(addition))
...:
<class 'pandas.core.frame.DataFrame'>
In [8]:
IPython console
History log
Permissions: RW
End-of-lines: CRLF
Encoding: UTF-8
Line: 1
Column: 1
Memory: 87 %

Part 2. 데이터 입출력

Any Question?

Thank you.